

UNIVERSIDADE ESTADUAL PAULISTA

“JÚLIO DE MESQUITA FILHO”

CIÊNCIA DA COMPUTAÇÃO

INTRODUÇÃO À CIÊNCIA DE DADOS

Pedro Alonso Oliveira dos Santos

Rennan Furlaneto Collado

Plano de Negócios: Sistema Preditivo de Riscos de Saúde (SPRS)

Docente: Prof. Dr. Danillo Roberto Pereira

Presidente Prudente/SP

2026

Sumário

Plano de Negócios: Sistema Preditivo de Riscos de Saúde (SPRS)	3
1. Sumário Executivo	3
2. Definição do Problema e Justificativa	4
3. Metodologia e Dados	5
4. Engenharia e Seleção de Características	7
5. Refinamento, Ajuste Fino e Resultados	8
5.1 Tarefa binária — os modelos empatam; vence a simplicidade	10
5.2 Tarefa de severidade — o critério de negócio muda o vencedor	10
5.3 Decisão de produto	12
6. Viabilidade Técnica e Infraestrutura	12
7. Plano de Negócio e Estratégia Comercial	15
8. Projeção Financeira de 2 Anos	16
9. Segurança de Dados e Conformidade Regulatória (LGPD, ANVISA, CFM)	18
10. Estratégia de Produção e Monitoramento	20
11. Relatório de Viabilidade e Recomendação Final	21
12. Próximos Passos	23
13. Referências	23

Plano de Negócios: Sistema Preditivo de Riscos de Saúde (SPRS)

Este documento detalha a viabilidade técnica e comercial de uma solução de Ciência de Dados aplicada à predição de doenças crônicas, iniciando por cardiopatias, com foco no mercado B2B hospitalar. Em relação à sua primeira versão, esta edição consolida o refinamento técnico da modelagem (seleção de características e ajuste fino dos modelos), o detalhamento completo da estrutura de custos e das projeções financeiras, e um relatório de viabilidade que avalia criticamente a possibilidade real de implementação do projeto.

1. Sumário Executivo

O SPRS é uma plataforma SaaS (Software as a Service) voltada para hospitais e clínicas. Através de modelos de Machine Learning treinados em bases de dados reais, o sistema processa dados clínicos para inferir o nível de gravidade de cardiopatias presentes no paciente. Essa classificação é apresentada em uma escala de 0 a 4, em que o grau 0 indica a ausência da patologia e o grau 4 representa um quadro de severidade crítica. O modelo de capitalização é baseado em assinaturas mensais pré-pagas por volume de uso, garantindo previsibilidade de faturamento e baixo custo operacional inicial.

Esta versão final aprofunda a proposta inicial em cinco frentes que a transformam numa solução tecnicamente refinada e potencialmente viável para aplicação real. Em primeiro lugar, formaliza-se a seleção de características, com métodos baseados em correlação, importância de atributos, regularização e eliminação recursiva. Em segundo, descreve-se o ajuste fino (fine tuning) dos modelos, com validação cruzada e análise explícita de overfitting. Em terceiro, o modelo de custos passa a contemplar o

pró-labore dos fundadores e a manutenção do sistema de Machine Learning, itens ausentes na primeira versão. Em quarto, a projeção financeira ganha granularidade mensal ao longo de 24 meses, com três cenários e cálculo formal de retorno sobre o investimento. Por fim, acrescenta-se um relatório de viabilidade que cobre as dimensões técnica, financeira, de adoção/regulatória e de produção.

No cenário realista, os números de referência são: break-even operacional no décimo segundo mês, payback do caixa acumulado no décimo oitavo mês e retorno sobre o investimento de aproximadamente 196% ao final dos 24 meses. O capital inicial mínimo recomendado é de R\$ 15.000,00, suficiente para financiar a operação até o início da receita recorrente.

Cabe registrar como o produto se materializou após a modelagem. A solução opera em duas tarefas complementares: uma triagem binária (presença ou ausência de doença) e a escala ordinal de gravidade de 0 a 4, o Risk Thermometer. A triagem binária atingiu desempenho sólido e auditável e constitui o núcleo confiável do produto; a escala completa de cinco níveis, substancialmente mais difícil, foi entregue como camada de priorização assistiva, ainda em amadurecimento. Assim, o diferencial da estratificação gradual se preserva em caráter preliminar, apoiado por uma triagem robusta — configuração detalhada na Seção 5.

2. Definição do Problema e Justificativa

As doenças cardiovasculares representam a principal causa de morte global e impõem um fardo econômico severo aos sistemas de saúde. No Brasil, dados do Datasus e da Firjan Sesi indicam que a insuficiência cardíaca foi responsável por gastos de R\$ 1,4 bilhão em hospitalizações entre 2018 e 2021, resultando em mais de 77 mil óbitos no período. O impacto financeiro é agravado pela alta complexidade das internações, que chegam a representar cerca de 40% dos custos diretos do tratamento de cardiopatias.

Enquanto o custo de uma consulta ambulatorial de acompanhamento é reduzido, o gasto médio por paciente internado pode ultrapassar R\$ 4.000,00 anuais, com diárias em Unidades de Tratamento Intensivo (UTI) custando quase o dobro das enfermarias comuns, com base em dados de 2002~2004 — hoje, corrigindo pela inflação, esses valores passariam facilmente de R\$ 15.000,00. A solução SPRS atua diretamente nessa eficiência financeira: ao inferir a gravidade da doença em uma escala de 0 a 4, o sistema permite que o hospital identifique pacientes em estágios iniciais e direcione intervenções preventivas.

Essa tomada de decisão clínica proativa evita que casos de menor gravidade evoluam para quadros críticos (Graus 3 e 4), que exigem hospitalizações prolongadas e exames de alto custo. Ao reduzir a taxa de reinternações e otimizar a ocupação de leitos, o software não apenas salva vidas, mas preserva a sustentabilidade financeira da instituição, convertendo gastos emergenciais reativos em uma gestão de saúde preventiva e economicamente inteligente.

3. Metodologia e Dados

O modelo utiliza bases de dados públicas consagradas (como UCI Machine Learning Repository e Kaggle). A análise exploratória de dados (EDA) foca em:

- Compreender a natureza e, principalmente, a integridade dos dados;
- Extrair os primeiros insights do modelo a partir dos dados;
- Priorização de variáveis para a classificação.

O treinamento é conduzido sobre o dataset Heart Disease UCI, que reúne 920 registros provenientes de quatro centros clínicos — Cleveland (EUA), Hungria, Suíça e VA Long Beach (EUA) —, coletados entre 1988 e 1991. A análise exploratória, consolidada no notebook 03_eda_final.ipynb, aprofundou o exame de integridade e identificou três limitações estruturais que orientam tanto a seleção de características quanto a

estratégia de modelagem.

A primeira limitação é a presença expressiva de valores ausentes, boa parte deles disfarçada. Variáveis diagnósticas de alto valor apresentam ausência elevada e concentrada por centro de coleta, num padrão Missing Not At Random (MNAR) — isto é, a ausência do dado está correlacionada com o protocolo do centro, não com o acaso. Além disso, colunas como chol (colesterol) e trestbps (pressão arterial de repouso) contêm zeros fisiologicamente impossíveis, que foram tratados como ausentes. O quadro a seguir resume os casos mais críticos:

Variável	Ausência	Padrão observado
ca (vasos na fluoroscopia)	66,4%	~99% ausente na Hungria e VA Long Beach; ~96% na Suíça
thal (cintilografia com tálcio)	52,8%	~90% ausente na Hungria; ~83% no VA Long Beach
slope (inclinação do segmento ST)	33,6%	~65% ausente na Hungria; ~51% no VA Long Beach
chol (colesterol)	172 zeros	Zeros impossíveis → tratados como ausência
trestbps (pressão de repouso)	28 zeros + MNAR	Zeros impossíveis e ausência por centro

A natureza MNAR desses vazios tem consequência prática direta: técnicas simples de imputação (média, mediana ou KNN univariado) podem introduzir viés sistemático, pois os valores imputados não representam a distribuição real do dado ausente. Por isso, a decisão de descartar ou imputar ca e thal é documentada com justificativa clínica e

estatística, e nenhum valor ausente é imputado silenciosamente.

A segunda limitação é um viés de seleção por centro de coleta. A prevalência de doença varia drasticamente entre as origens: 45,7% em Cleveland, 36,2% na Hungria, 74,5% no VA Long Beach e 93,5% na Suíça, contra uma média geral de 55,3%. A prevalência suíça, próxima da totalidade da amostra, é sinal inequívoco de que aquele centro provavelmente recrutou apenas pacientes com suspeita clínica severa. Sem tratamento, o modelo tenderia a aprender que "ser do centro suíço" prediz doença com cerca de 93% de probabilidade — um artefato do desenho da coleta, não da fisiologia. As mitigações previstas são a ponderação de amostras pela prevalência de cada centro, a estratificação por centro na validação cruzada e a inclusão da origem como covariável explícita.

A terceira limitação é o risco de generalização geográfica. O modelo é treinado em dados norte-americanos e europeus de 1988–1991, mas o produto se destina a hospitais brasileiros em 2026. Diferenças epidemiológicas relevantes — maior prevalência de doença reumática cardíaca no Brasil, inclusive em adultos jovens; diversidade regional do perfil lipídico; e acesso desigual a exames complementares, de modo que *ca* e *thal* podem sequer estar disponíveis no contexto do SUS — podem alterar a relação entre as variáveis e o desfecho na população-alvo. A mitigação planejada para os meses 18 a 24 é a constituição de uma coorte brasileira de validação (200 a 500 casos), em parceria com um hospital universitário como o HC-UNICAMP ou o InCor-USP, adotando como critério mínimo de qualidade um F1-score brasileiro de pelo menos 85% do valor obtido no conjunto UCI.

4. Engenharia e Seleção de Características

A engenharia de características foi implementada como uma sequência de transformadores no padrão *scikit-learn* (*fit/transform*), encaixável integralmente na validação cruzada: os parâmetros — limites de imputação, quantis de winsorização, escalonadores — são aprendidos apenas no treino de cada fold e aplicados ao fold de

validação, sem vazamento (garantia verificada por um teste de sanidade dedicado). O fluxo tem seis etapas: conversão em ausência dos zeros clinicamente impossíveis de chol e trestbps; criação de indicadores binários de ausência (<coluna>_missing), já que a ausência estrutural por centro carrega sinal MNAR — o indicador slope_missing figura, aliás, entre as dez variáveis de maior informação mútua com o alvo, à frente da própria idade; imputação multivariada tratada em três grupos conforme o mecanismo de ausência (dos mais leves, por MICE com BayesianRidge, a ca e thal, de ausência extrema, isolados num sub-pipeline próprio), sempre condicionada em idade, sexo e centro; criação de variáveis clínicas derivadas (faixas etárias, categorias de colesterol e pressão, log1p de oldpeak e interações sexo × variável clínica); winsorização dos extremos (percentis 1% e 99%) em vez de remoção de pacientes; e encoding condicionado à família do modelo (ordinal para árvores, RobustScaler com one-hot para lineares).

A seleção de características, por sua vez, é exploratória e orientada por decisão humana, não uma filtragem automática. O ranking de informação mútua com o alvo confirma que cp (tipo de dor torácica, 0,163), ca (número de vasos, 0,153) e exang (angina ao esforço, 0,107) carregam o maior sinal, seguidos de thalch, oldpeak, sex, chol e thal; o relatório de VIF sinaliza multicolinearidade elevada nos termos de interação sex_x_age ($\approx 19,5$) e sex_x_thalch ($\approx 15,0$), mantidos deliberadamente por só alimentarem os modelos lineares, cujo objetivo ali é prever, não interpretar coeficientes. A decisão de seleção mais importante para o produto, contudo, é negativa: o centro de coleta (dataset) é excluído das variáveis do modelo. Deixá-lo entrar permitiria aprender o atalho "centro X $\Rightarrow$ doente", que reflete o viés de amostragem descrito na Seção 3, não a fisiologia, e que não generalizaria para um novo hospital cliente. Essa exclusão é a principal salvaguarda de generalização no contexto B2B multicliente.

5. Refinamento, Ajuste Fino e Resultados

O produto foi modelado em duas tarefas complementares sobre a mesma base. A tarefa binária (presença ou ausência de doença, derivada de $\text{num} > 0$) funciona como filtro de triagem — decide quem entra na fila de acompanhamento. A tarefa de severidade (a escala ordinal num , de 0 a 4) funciona como priorização dentro da fila — decide a ordem e a intensidade da intervenção. A base de 920 pacientes é dividida uma única vez em treino e teste (736 e 184 registros no grupo completo), com estratificação simultânea por doença, sexo e centro para que nenhuma origem se concentre por acaso no teste, que só é tocado na avaliação final. Modelos restritos a homens e mulheres também são treinados, como análise de robustez — não como segmentação de produto —, ressaltando-se que o subgrupo feminino tem apenas 39 casos de teste, insuficientes para conclusões definitivas.

Seis algoritmos são comparados sob o mesmo protocolo: Regressão Logística e SVM (família linear) e Random Forest, XGBoost, LightGBM e CatBoost (família de árvores). Para cada um faz-se busca exaustiva em grade (de 8 a 54 combinações de hiperparâmetros), avaliada por validação cruzada estratificada e repetida — 5 folds $\times$ 5 repetições, ou seja, 25 execuções por combinação —, o que reduz a variância da estimativa antes da comparação. A ROC AUC é a métrica primária de seleção; a combinação vencedora é retreinada do zero com 100% do treino e avaliada uma única vez no teste. Como todo o pré-processamento roda dentro da validação cruzada (Seção 4), as estimativas são livres de vazamento, e as métricas multiclasse usam média macro para não mascarar o desempenho nas classes graves minoritárias.

Um cuidado é decisivo na severidade: por ser um problema ordinal, confundir o grau 4 com o grau 0 é muito mais grave — clínica e economicamente — do que confundi-lo com o grau 3, e subestimar a gravidade é mais perigoso que superestimá-la. Por isso o painel foi estendido com diagnósticos ordinais — QWK (kappa quadrático ponderado), MAE em número de graus, taxa de acerto dentro de um grau e um score de risco clínico assimétrico, que pune a subestimação mais que a superestimação. É esse score, não a ROC AUC, que decide o modelo de severidade que vai a produção.

5.1 Tarefa binária — os modelos empatam; vence a simplicidade

Modelo	ROC AUC	Acurácia balanceada	F1	MCC
CatBoost	0,888	0,784	0,824	0,581
Regressão Logística	0,884	0,824	0,843	0,648
SVM	0,884	0,808	0,840	0,625
Random Forest	0,883	0,818	0,839	0,637
XGBoost	0,875	0,784	0,812	0,570
LightGBM	0,861	0,767	0,798	0,536

Desempenho no teste (grupo completo, $n = 184$). Melhor configuração da Regressão Logística: $C = 0,1$, $\text{class_weight} = \text{balanced}$, $\text{solver} = \text{lbfgs}$.

Na triagem, os seis modelos são estatisticamente indistinguíveis — a ROC AUC varia apenas de 0,861 a 0,888, dentro do desvio-padrão de validação cruzada de qualquer um deles. O desempate vem das métricas de equidade entre classes e do custo operacional, e ambos apontam para a Regressão Logística: ela tem a maior acurácia balanceada (0,824), o maior F1 (0,843) e o maior MCC (0,648), com acurácia global de 82,6% e recall de 84,3%, além de ser a mais rápida de treinar e retreinar, a mais barata de manter e a mais fácil de auditar e explicar a um cliente hospitalar. Esses números superam com folga os limiares mínimos de uma triagem clínica (acurácia $\geq 80\%$, recall $\geq 80\%$, F1 $\geq 75\%$ e AUC $\geq 0,80$): a tarefa binária é o núcleo confiável do produto.

5.2 Tarefa de severidade — o critério de negócio muda o vencedor

Modelo	ROC AUC	QWK	MAE	Dentro de 1 grau	Subestima	Risco clínico
Random Forest	0,806	0,373	0,690	80,4%	33,7%	1,897
CatBoost	0,805	0,444	0,663	81,0%	30,4%	1,745
SVM	0,801	0,470	0,647	82,1%	30,4%	1,685
XGBoost	0,796	0,408	0,696	80,4%	33,7%	1,864
Regressão Logística	0,797	0,325	0,717	78,8%	35,9%	2,065
LightGBM	0,782	0,438	0,717	80,4%	29,3%	1,840

Desempenho no teste (grupo completo, $n = 184$). Menor é melhor em MAE, subestimação e risco clínico. Melhor configuração do SVM: $C = 1,0$, kernel = rbf, gamma = scale.

A escala completa de cinco níveis é bem mais difícil: a acurácia fica em torno de 58% e o F1 macro em torno de 0,36, aquém do patamar de maturidade desejável para uma escala clínica. O Random Forest lidera nominalmente por ROC AUC (0,806), mas por margem irrelevante; em todas as métricas que carregam a assimetria de custo — QWK, MAE, acerto dentro de um grau e risco clínico — o SVM é o melhor, com a maior concordância ordinal (0,470), o menor erro médio (0,647 grau) e o menor risco clínico (1,685). A Regressão Logística, tão competitiva na triagem, é aqui a pior escolha: maior taxa de subestimação (35,9%) e maior risco clínico — o padrão de erro que o negócio precisa evitar. Como o multiplicador de penalidade adotado ($1,5\times$) é conservador,

recalibrá-lo para o custo real de uma internação apenas amplia a vantagem do SVM. Ainda assim, com QWK entre 0,33 e 0,47, nenhum modelo "resolve" a severidade de forma madura: o SVM é o melhor candidato atual, não uma solução pronta.

5.3 Decisão de produto

A leitura conjunta das duas tarefas define a forma final do produto. A triagem binária (Regressão Logística) cumpre os limiares e é o núcleo confiável — responde, com desempenho auditável, se o paciente merece atenção preventiva. A escala de severidade 0–4 (SVM), o Risk Thermometer, é entregue como camada de priorização assistiva, escolhida pelo menor risco clínico assimétrico, porém assumidamente ainda imatura: ordena a fila de acompanhamento sem substituir o julgamento médico. A contingência prevista, assim, concretiza-se de forma parcial — o argumento comercial ancora-se na triagem binária robusta, complementada pela priorização gradual em caráter preliminar —, o que reforça a importância da coorte brasileira de validação (Seção 3) para amadurecer a escala completa.

6. Viabilidade Técnica e Infraestrutura

A solução será implementada na nuvem Microsoft Azure, utilizando uma arquitetura moderna de serviços gerenciados para otimizar custos e garantir escalabilidade horizontal automática. O dimensionamento inicial, adequado ao MVP, distribui-se entre os seguintes serviços:

Serviço Azure	Função	Especificação		Custo (USD)
Static Web Apps	Interface (Frontend)	Standard (24/7)	Tier	\$9,00

Serviço Azure	Função	Especificação	Custo (USD)
Container Apps	Processamento (Backend/Modelo)	1 vCPU / 2 GiB RAM (escala até zero)	\$9,60
SQL Database	Controle de clientes	Basic Tier (5 DTUs)	\$6,90
Container Registry	Armazenamento do Docker	Basic Tier	\$5,16
Storage Account	Upload de CSVs	Blob Storage (LRS)	\$1,15

O uso do Container Apps garante a escalabilidade: o sistema processa desde uma entrada manual única até arquivos CSV com milhares de registros simultaneamente, ativando instâncias adicionais apenas durante o processamento. Do ponto de vista de complexidade computacional, os modelos candidatos (como Random Forest e XGBoost) realizam a inferência de um ponto único em menos de 10 milissegundos em CPU, plenamente compatíveis com a configuração de 1 vCPU e 2 GiB do tier inicial; o retreinamento, por sua vez, é um processo offline, executado sem afetar a disponibilidade da API de produção. Somando-se aos serviços de nuvem os demais custos operacionais — contabilidade (R\$ 600,00), jurídico e licenças (R\$ 400,00) e marketing e vendas, ou CAC (R\$ 500,00) —, além de uma alíquota conservadora de 6% de imposto sobre o faturamento, a estimativa de custo mensal para a manutenção da plataforma é de R\$ 1.658,10 + impostos.

Esse dimensionamento, todavia, corresponde ao cenário conservador. À medida que o volume de predições e o número de clientes crescem, a infraestrutura precisa escalar, e os custos acompanham esse movimento. Convém, portanto, prever três patamares.

No cenário conservador (até 10 clientes), mantém-se a configuração acima, com custo de infraestrutura de US\$ 31,81 mensais (cerca de R\$ 158,10). No cenário realista (de 11 a 25 clientes), o Container Apps sobe para 2 vCPU / 4 GiB e o banco para o tier Standard S1, elevando a infraestrutura a aproximadamente US\$ 50,66 (cerca de R\$ 251,78). No cenário otimista (26 clientes ou mais), a computação chega a 4 vCPU / 8 GiB e o banco ao Standard S2, resultando em cerca de US\$ 92,40 (aproximadamente R\$ 459,23). O custo fixo total mensal evolui, assim, de R\$ 1.658,10 no cenário conservador para R\$ 1.751,78 no realista e R\$ 1.959,23 no otimista (câmbio de referência de R\$ 4,97 por dólar, a ser atualizado pela cotação do Banco Central na data de entrega).

A primeira versão do plano contabilizava apenas os prestadores externos. Esta edição incorpora, de forma explícita, os custos de mão de obra. O Simples Nacional exige que os sócios que exercem função na empresa retirem pró-labore, distinto da distribuição de lucros; estimando-se o salário mínimo de 2026 em R\$ 1.518,00, o pró-labore mínimo para os dois fundadores seria de R\$ 3.036,00 mensais. Para viabilizar o payback no prazo projetado, adota-se a estratégia de sweat equity diferido, na qual essa remuneração é adiada até que o caixa acumulado atinja margem confortável após o payback — o que implica um valor diferido total da ordem de R\$ 54.648,00 ao longo de 18 meses. Sobre esse ponto, faz-se uma ressalva importante: o retorno sobre o investimento apresentado na Seção 8 não considera o pró-labore diferido; quando este é contabilizado como custo de oportunidade real, o retorno ajustado torna-se negativo, o que evidencia que o negócio é atrativo para fundadores comprometidos com a construção de patrimônio de longo prazo, não para quem busca retorno imediato sobre o próprio tempo. Sob a mesma lógica, prevê-se um esforço de manutenção do modelo (ML Ops) de cerca de 8 horas mensais no MVP e até 17 horas em escala, tratado como sweat equity até o payback e passível de externalização (R\$ 1.500,00 a R\$ 2.000,00 mensais) caso ultrapasse 20 horas por mês. Recomenda-se, ainda, uma reserva de contingência de R\$ 5.000,00, além do capital inicial, para custos pontuais como a consultoria jurídico-sanitária junto à ANVISA, a auditoria de segurança e o

design de interface.

7. Plano de Negócio e Estratégia Comercial

O modelo B2B foca em assinaturas mensais. Os clientes compram "créditos de análise" que expiram mensalmente. O plano Bronze oferece 150 usos por mês a R\$ 300,00; o Prata, 600 usos por R\$ 1.000,00; o Ouro, 1000 usos por R\$ 1.500,00; e o Enterprise, destinado a mais de 1000 usos mensais, é personalizado para cada lead. Para fidelização, concede-se desconto de 16% na assinatura anual. A estratégia de Go-to-Market tem início focado em clínicas especializadas em cardiologia, para validação do MVP, expandindo-se para hospitais gerais no segundo ano.

Esse percurso comercial pode ser organizado em cinco fases. Nos meses 1 a 4, a prioridade é o networking — participação em congressos de cardiologia, aproximação de cardiologistas e registro da empresa — com a meta de construir um pipeline de cinco a oito leads qualificados. Nos meses 5 e 6, realizam-se pilotos gratuitos do plano Bronze em duas clínicas, gerando casos de uso documentados para o material comercial. Dos meses 7 a 12, converte-se o piloto em contratos pagantes e busca-se o primeiro cliente Prata, atingindo o break-even operacional. Dos meses 12 a 18, aproxima-se de hospitais gerais e oferece-se o contrato anual, alcançando o payback e iniciando o processo regulatório junto à ANVISA. Por fim, dos meses 18 a 24, lançam-se os módulos de doenças renais e hepáticas (venda cruzada para a base existente) e inicia-se a integração com sistemas hospitalares, com a meta de superar R\$ 10.000,00 de receita recorrente mensal.

O acompanhamento comercial apoia-se em indicadores como a receita recorrente mensal (que deve evoluir de R\$ 2.200,00 no mês 12 para R\$ 10.800,00 no mês 24), a taxa de churn (mantida abaixo de 2% ao mês), o custo de aquisição de cliente (abaixo de R\$ 750,00), o lifetime value (superior a R\$ 20.000,00) e, sobretudo, a razão entre ambos: a relação LTV:CAC projetada para o mês 12, de aproximadamente 34,5 vezes, situa-se muito acima do mínimo de referência de 3 vezes usual em SaaS B2B,

indicando uma economia de unidade saudável.

Vale observar que o argumento comercial depende do resultado da modelagem. Se o alvo multiclasse for viabilizado, o discurso de venda gira em torno da estratificação de gravidade em escala de 0 a 4 — o médico sabe não apenas se há doença, mas quão grave ela é —, um diferencial claro frente a ferramentas convencionais. Se apenas a classificação binária for atingida, o posicionamento migra para a triagem rápida de risco cardíaco, acompanhada da análise de erro por severidade; um produto ainda útil, porém menos diferenciado, o que pode pressionar o ticket do plano Prata em 10% a 20% e recomenda concentrar os primeiros meses em clínicas menores, ainda sem qualquer ferramenta de triagem computacional.

8. Projeção Financeira de 2 Anos

Com um custo de infraestrutura estimado em aproximadamente R\$ 1.650,00/mês, o ponto de equilíbrio (break-even) é atingido com o fechamento dos primeiros contratos de pequeno porte. No Ano 1, o foco é a aquisição de 5 a 8 clientes iniciais e a estabilização do modelo; no Ano 2, a expansão da base de clientes e o aumento do ticket médio por meio de módulos adicionais (Rim e Fígado). A projeção parte de uma perspectiva realista/pessimista, construída sobre o seguinte storytelling: nos meses 1 a 4, há prospecção ativa, participação em fóruns e conferências de medicina e estabelecimento do networking inicial, ainda sem fechar assinaturas; nos meses 5 e 6, fecham-se um ou dois clientes com planos Bronze gratuitos, para que validem a ferramenta internamente, sem compromisso financeiro; nos meses 7 a 12, transita-se do primeiro cliente Bronze ao primeiro Prata — os Bronze são clínicas de cardiologia pequenas e médias, e os primeiros Prata devem ser hospitais pequenos e clínicas especializadas de grande porte —, e é aqui que ocorre o break-even; nos meses 13 a 24, com o lançamento dos módulos renal e hepático e o networking dos clientes já captados, a base cresce, e no mês 18 a receita líquida acumulada sai do vermelho.

Esta versão traduz o storytelling em uma projeção mês a mês, calculada pela fórmula $\text{Lucro_mensal} = \text{Receita_bruta} \times 0,94 - \text{R\$ } 1.658,10$, na qual o fator 0,94 corresponde ao desconto dos 6% do Simples Nacional. A tabela abaixo destaca os marcos da curva no cenário realista, medindo o volume de clientes em contratos Bronze (B) e Prata (P):

Mês	Fase	Mix	Receita bruta	Lucro mensal	Caixa acumulado
1–6	Networking e MVP gratuito	0B + 0P	R\$ 0,00	–R\$ 1.658,10	até –R\$ 9.948,60
11	Tração inicial	4B	R\$ 1.200,00	–R\$ 530,10	–R\$ 14.855,10 (pico do déficit)
12	Break-even	4B + 1P	R\$ 2.200,00	+R\$ 409,90	–R\$ 14.445,20
18	Payback	8B + 4P	R\$ 6.400,00	+R\$ 4.357,90	+R\$ 2.396,20
24	Meta	16B + 6P	R\$ 10.800,00	+R\$ 8.493,90	+R\$ 44.053,60

A curva de caixa percorre três fases. Na fase de déficit (meses 1 a 11), há queda linear de R\$ 1.658,10 ao mês, atingindo o ponto mais negativo ao fim do mês 11, em –R\$ 14.855,10 — valor que corresponde ao capital total consumido e serve de base para o cálculo de retorno. Na fase de recuperação (meses 12 a 17), a entrada do primeiro cliente Prata e a expansão da carteira elevam o lucro mensal de R\$ 409,90 a mais de R\$ 4.000,00, reduzindo progressivamente o déficit acumulado. Na fase de aceleração (meses 18 a 24), o caixa acumulado cruza o zero no mês 18 e, com carteiras de 8 a 16

clientes, acumula cerca de R\$ 44.000,00 até o mês 24.

Esse desfecho, contudo, é sensível às premissas de aquisição e retenção, o que motiva a análise de três cenários. No cenário realista, descrito acima, o break-even ocorre no mês 12 e o payback no mês 18. No cenário pessimista (aquisição 40% mais lenta e churn de 5% ao mês), o break-even recua para os meses 15 ou 16 e o caixa acumulado ao fim de 24 meses oscila entre -R\$ 2.000,00 e +R\$ 3.000,00 — ou seja, o negócio não fecha dentro do horizonte sem aporte adicional ou ajuste de estratégia, como a migração de clientes Bronze para Prata, o foco em hospitais de maior ticket ou a redução do churn por meio de um onboarding mais robusto. No cenário otimista (aquisição 30% mais rápida, entrada de clientes Ouro e churn de 1%), o break-even antecipa-se para o mês 10 e a receita recorrente ao fim do período aproxima-se de R\$ 19.000,00 mensais.

Sobre o capital consumido, calcula-se o retorno sobre o investimento. Tomando o pico do déficit (R\$ 14.855,10) como investimento total e o caixa acumulado ao mês 24 (R\$ 43.959,70) como retorno, obtém-se um ROI de aproximadamente 196% em 24 meses — cerca de 98% ao ano. Em outras palavras, para cada real investido no financiamento do déficit inicial, o negócio devolve cerca de R\$ 2,96 ao fim de dois anos, patamar muito superior ao de uma aplicação conservadora indexada à taxa Selic no mesmo período. Reitere-se, porém, a ressalva já feita: esse cálculo não incorpora o custo de oportunidade do tempo dos fundadores; contabilizado o pró-labore diferido, o retorno ajustado torna-se negativo, e o mérito do investimento passa a residir na construção de patrimônio, não no retorno financeiro imediato.

9. Segurança de Dados e Conformidade Regulatória (LGPD, ANVISA, CFM)

O sistema opera sob o princípio de Data Minimization. Não há armazenamento permanente de dados clínicos identificáveis. Após o processamento da predição e

geração do relatório, os dados de entrada são descartados, mantendo-se apenas o log de volume para fins de faturamento.

Esse princípio se materializa em obrigações concretas sob a LGPD (Lei 13.709/2018). Dados de saúde são dados sensíveis (Art. 11), cuja base legal, no caso do SPRS, é a tutela da saúde por profissionais e serviços de saúde. No modelo B2B, o hospital ou clínica cliente atua como controlador — decide por que e como os dados do paciente são tratados e responde pelo consentimento —, enquanto o SPRS atua como operador, processando os dados estritamente sob instrução do controlador e respondendo pela segurança técnica. Dessa divisão decorrem instrumentos obrigatórios: um Acordo de Operação de Dados (DPA) firmado com cada cliente; um Relatório de Impacto à Proteção de Dados (RIPD) elaborado antes do processamento em escala; e a designação de um Encarregado (DPO), papel assumido por um dos fundadores durante o MVP. Eventuais incidentes de segurança devem ser notificados à ANPD no prazo legal de 72 horas.

Uma dimensão regulatória ausente na primeira versão, e crítica para a comercialização, é o enquadramento do produto como Software como Dispositivo Médico (SaMD), regido pela Resolução RDC nº 40/2022 da ANVISA. Como o SPRS processa dados clínicos individualizados para gerar um score de gravidade com finalidade de apoio diagnóstico, ele se enquadra como SaMD. A classificação de risco depende do papel do software na decisão clínica: posicionado como ferramenta que informa o médico — que mantém a decisão —, o produto é de Classe II; qualquer comunicação que sugira diagnóstico autônomo o elevaria à Classe III, com requisitos substancialmente maiores. O enquadramento como Classe II exige registro na ANVISA antes da comercialização, com dossiê técnico de validação e plano de pós-comercialização, num prazo estimado de 6 a 12 meses. Comercializar sem registro configura infração sanitária, sujeita a multa de R\$ 2.000,00 a R\$ 1.500.000,00, o que torna imperativo iniciar a consultoria jurídico-sanitária entre os meses 6 e 8.

Soma-se a isso a Resolução CFM nº 2.338/2023, que disciplina o uso de inteligência

artificial na prática médica e estabelece que o médico retém a autoridade e a responsabilidade final sobre a decisão. Disso derivam requisitos obrigatórios de interface: cada resultado deve vir acompanhado de aviso explícito de que se trata de ferramenta de apoio, cabendo a decisão ao profissional; deve-se exibir a confiança estimada do modelo junto ao score; deve haver trilha de auditoria anonimizada; e a comunicação comercial não pode empregar termos como "diagnostica" ou "substitui o médico", mas sim "apoia a triagem" e "estratifica risco para revisão médica". Por fim, para viabilizar a integração com os sistemas de prontuário eletrônico do mercado, adota-se o padrão HL7 FHIR R4, de forma faseada: na primeira versão, o operador hospitalar realiza o upload manual de CSV; na segunda, uma API REST compatível com FHIR permite a integração direta com hospitais de médio e grande porte.

As barreiras de adoção mais relevantes — os longos ciclos de compra hospitalar, a resistência ao uso de IA percebida como "caixa preta" e a pendência do registro sanitário — são mitigadas, respectivamente, pelo foco inicial em clínicas privadas de decisão ágil, pela exibição transparente da importância das variáveis e da confiança do modelo, e pela operação em caráter de piloto e pesquisa até a obtenção do registro.

10. Estratégia de Produção e Monitoramento

A colocação da solução em produção apoia-se na arquitetura Azure já descrita, na qual a requisição do cliente chega ao frontend (Static Web Apps), é encaminhada ao backend (Container Apps, com a API e o modelo serializado) e, após a inferência realizada em memória, retorna o resultado. Uma decisão de projeto assegura a conformidade com a LGPD: os dados clínicos transitam exclusivamente em memória durante a inferência e nunca são persistidos; o banco de dados guarda apenas metadados anonimizados de volume, e o arquivo de entrada é descartado em no máximo uma hora, por uma rotina automatizada.

Como o modelo é treinado em dados antigos e receberá, em produção, dados de pacientes atuais, o monitoramento de deriva é essencial — sobretudo porque a

degradação pode ocorrer silenciosamente, sem erro aparente, o que é especialmente grave em saúde. Adota-se, para isso, o Population Stability Index (PSI), calculado mensalmente sobre as variáveis de entrada e sobre a distribuição do score de saída. A leitura segue faixas consagradas: um PSI inferior a 0,10 indica distribuição estável, exigindo apenas monitoramento de rotina; entre 0,10 e 0,20, sinaliza deriva moderada, que motiva investigação da causa raiz; e acima de 0,20, caracteriza deriva significativa, que dispara o retreinamento. Esse monitoramento é operacionalizado por um script agendado, que emite alerta automático quando qualquer variável crítica ultrapassa o primeiro limiar, e é consolidado em um relatório mensal de desempenho — contendo volume de uso por cliente, PSI por variável, distribuição dos scores em comparação com o baseline e métricas de infraestrutura (latência, taxa de erros e disponibilidade).

O retreinamento é acionado por gatilhos objetivos: PSI acima de 0,20 em variável crítica por dois meses consecutivos; queda superior a 5 pontos percentuais no F1-score macro frente ao baseline de lançamento; variação superior a 15 pontos percentuais na proporção de predições de graus 3 ou 4 sem causa clínica conhecida; ou discordância clínica sistemática, reportada pelo cliente, em mais de 10% dos casos revisados. Independentemente de alertas, há revisão obrigatória a cada seis meses. O processo de retreinamento compreende a curadoria dos dados, a reexecução da EDA e da seleção de características, o treino com validação cruzada estratificada por centro, a comparação A/B contra o modelo em produção sobre um conjunto de teste fixo, a validação manual de cerca de 50 casos por um médico parceiro e, aprovado o novo modelo, o deploy por meio de nova imagem versionada, com monitoramento intensificado nos 30 dias seguintes e possibilidade de reversão rápida em caso de regressão. Cada modelo em produção recebe versionamento semântico.

11. Relatório de Viabilidade e Recomendação Final

A síntese das quatro dimensões avaliadas conduz a uma recomendação de viabilidade com ressalvas. Na dimensão técnica, o projeto é condicionalmente viável: apesar das

limitações estruturais dos dados (ausência elevada em ca e thal, viés de seleção suíço e risco de generalização para o Brasil), a triagem binária atingiu os limiares definidos com folga — Regressão Logística com AUC 0,884, acurácia 82,6%, F1 0,843 e recall 84,3% —, constituindo um núcleo confiável; já a escala de severidade 0–4, embora funcional (SVM, o melhor pelo critério de risco clínico), permanece imatura (QWK $\approx$ 0,47) e é entregue apenas como camada de priorização assistiva. O Risk Thermometer pleno, portanto, depende de mais dados para amadurecer. Na dimensão financeira, é viável: break-even no mês 12, payback no mês 18, ROI de $\sim$ 196% e relação LTV:CAC de 34,5 vezes, ressalvado o cenário pessimista, que não fecha em 24 meses. Na dimensão regulatória, é viável mediante pré-requisitos: o registro ANVISA como SaMD Classe II, os requisitos de interface do CFM e os instrumentos de LGPD. Na dimensão de adoção, é viável com estratégia conservadora, iniciando por clínicas privadas de menor porte e usando o plano Bronze como porta de entrada de baixa fricção.

A recomendação de "viável com ressalvas" apoia-se em fundamentos econômicos sólidos, em uma arquitetura adequada ao MVP e em um mercado-alvo com problema documentado e mensurável. As ressalvas, por sua vez, são condições de prosseguimento que devem ser cumpridas antes da comercialização e podem ser lidas como gates de decisão. A primeira é técnica e já foi parcialmente resolvida: a triagem binária superou seus limiares ($F1 \geq 75\%$, $AUC \geq 0,80$) e é aprovada como núcleo do produto; a escala de severidade, que não alcançou o patamar pleno de maturidade, segue como priorização assistiva, condicionada ao amadurecimento com a coorte brasileira de validação antes de ser comunicada como diagnóstico gradual definitivo. A segunda e a terceira são regulatórias: iniciar o protocolo de registro na ANVISA entre os meses 6 e 8 e implementar os requisitos de interface do CFM antes do primeiro cliente pagante. A quarta é financeira: assegurar o capital inicial de R\$ 15.000,00 e a reserva de contingência de R\$ 5.000,00. A quinta refere-se aos dados: firmar, a partir do mês 18, um plano formal de validação com coorte de pacientes brasileiros. Como condições de interrupção após o lançamento, monitoram-se um churn mensal acima de 3% por três meses consecutivos, um PSI acima de 0,20 por dois meses e a não

obtenção do break-even até o mês 15.

12. Próximos Passos

- Desenvolvimento dos modelos preditivos para doenças renais e hepáticas.
- Implementação de indicadores de sucesso (KPIs) como Acurácia, Recall e F1-Score do modelo em produção.
- Integração via API com sistemas de prontuário eletrônico (HIS) existentes no mercado.
- Consolidação das métricas finais do modelo (seleção de características e ajuste fino) e definição do alvo definitivo — multiclasse ou binário.
- Contratação de assessoria jurídico-sanitária para o processo de registro na ANVISA e implementação dos requisitos de interface do CFM antes do primeiro cliente pagante.
- Assinatura do primeiro piloto gratuito com clínica de cardiologia parceira e formalização de parceria com hospital universitário para a coorte brasileira de validação.

13. Referências

AGÊNCIA BRASIL. *Gastos com internações por insuficiência cardíaca chegam a R\$ 1,4 bi.* Brasília: EBC, jul. 2022.

ANPD. *Guia Orientativo para Tratamento de Dados de Saúde.* Brasília: ANPD, 2023.

ANVISA. *Resolução RDC nº 40, de 26 de maio de 2022* (Software como Dispositivo Médico — SaMD). D.O.U., Brasília, 2022.

ARAUJO, Denizar Vianna et al. *Custo da insuficiência cardíaca no Sistema Único de Saúde.* Arquivos Brasileiros de Cardiologia, São Paulo, v. 84, n. 5, maio 2005.

CFM. *Resolução CFM nº 2.338/2023* (Inteligência Artificial na Medicina). Brasília: CFM, 2023.

HL7 INTERNATIONAL. *FHIR R4 Specification*. Disponível em: <https://hl7.org/fhir/R4/>.

JANOSI, A.; STEINBRUNN, W.; PFISTERER, M.; DETRANO, R. *Heart Disease Dataset*. UCI Machine Learning Repository, 1988.

MICROSOFT. *Pricing Calculator*. Microsoft Azure, [2026]. Disponível em: <https://azure.microsoft.com/pt-br/pricing/calculator/>.

SIDDIQI, N. *Credit Risk Scorecards: Developing and Implementing Intelligent Credit Scoring*. Wiley, 2006.

SONY, Redwan Karim. *Heart Disease Data*. Kaggle, 23 set. 2020. Disponível em: <https://www.kaggle.com/datasets/redwankarimsony/heart-disease-data>.

BRASIL. *Lei nº 13.709, de 14 de agosto de 2018* (Lei Geral de Proteção de Dados Pessoais — LGPD). Brasília, 2018.